

# 컴퓨터 응용통계

## 8장 이표본 t-test

최경미

## 이표본 t-test


사과냐? 배냐?

$$H_0: \text{사과} = \text{배}$$


$$H_1: \text{사과} \neq \text{배}$$

## 두 집단의 평균 비교

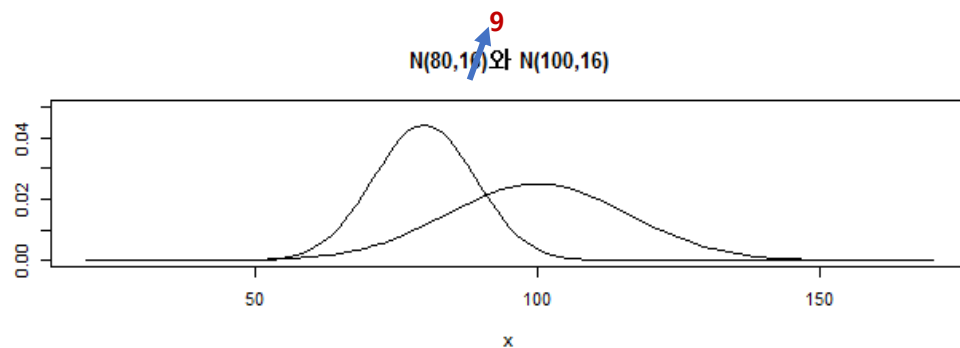
- 가설  $H_0: \mu_1 = \mu_2$  vs.  $H_1: \mu_1 \neq \mu_2$
- 분산이 작으면, 평균이 달라 보이고,  
분산이 크면, 평균이 같아 보임.
- 분산이 다를 때는 .....



등분산



등분산



이분산

# 독립인 두 표본의 평균비교

- 등분산성(equal variances) 검정
  - ① 등분산이면 등분산 이표본  $T$  –검정
  - ② 분산이 다르면 이분산(non-equal variances) 이표본  $T$  –검정

## 8.1 이분산 $T$ -검정

- $X_1, X_2, \dots, X_{n_1} \sim \text{iid } N(\mu_1, \sigma_1^2)$
- $Y_1, Y_2, \dots, Y_{n_2} \sim \text{iid } N(\mu_2, \sigma_2^2)$
- 독립표본

•  $\sigma_1^2 \neq \sigma_2^2$  가정

• 가설  $H_0: \mu_1 = \mu_2$  vs.  $H_1: \mu_1 \neq \mu_2$

$$\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i$$


$$S_1^2 = \frac{1}{n_1-1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2, S_2^2 = \frac{1}{n_2-1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2$$

$$E[\bar{X} - \bar{Y}] = \mu_1 - \mu_2$$

$$\text{Var}(\bar{X} - \bar{Y}) = \text{Var}(\bar{X}) + (-1)^2 \text{Var}(\bar{Y}) - 2\text{Cov}(\bar{X}, \bar{Y}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$$

$$\text{Var}(\widehat{\bar{X} - \bar{Y}}) = \frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}$$

$$se(\bar{X} - \bar{Y}) = \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$$



$$t = \frac{Z}{\sqrt{\frac{\chi^2(r)}{r}}} \sim t(r)$$

$$\text{검정통계량 } T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{S_1^2/n_1 + S_2^2/n_2}} \sim t(df)$$


$$\text{Satterthwaite의 자유도 } df = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

$\mu_1 - \mu_2$ 의  $100(1-\alpha)\%$  신뢰구간

$$\left( \bar{X} - \bar{Y} - t_{\alpha/2}(df) \sqrt{S_1^2/n_1 + S_2^2/n_2}, \right. \\ \left. \bar{X} - \bar{Y} + t_{\alpha/2}(df) \sqrt{S_1^2/n_1 + S_2^2/n_2} \right)$$

$$\text{기각역 } R: |T| \geq t_{\alpha/2}(df)$$

$$\text{유의확률 } p\text{-값} = P(|T| \geq |t_0|)$$



## 예제 8.2 mtcars자료 표8.1에서 4기통 차와 6기통 차의 평균연비 비교

```
> x<-c(22.8, 24.4, 22.8, 32.4, 30.4, 33.9, 21.5, 27.3, 26.0, 30.4, 21.4), n1 = 11
```

```
> y<-c(21.0, 21.0, 21.4, 18.1, 19.2, 17.8, 19.7), n2 = 7
```

```
> mean(x)
```

```
> mean(y)
```

```
> sd(x)
```

```
> sd(y)
```

```
> mydata<-c(x,y)
```


```
> m<-length(x)
```

```
> n<-length(y)
```

```
> mygroup<-c(rep("4",m),rep("6",n))
```

```
> boxplot(mydata~mygroup, ylab="mpg")
```

실린더 수↵	평균↵	표준편차↵
4↵	26.66↵	4.51↵
6↵	19.74↵	1.45↵



> # 평균 검정

$H_0: \mu_1 = \mu_2$  vs.  $H_1: \mu_1 \neq \mu_2$

> t.test(x,y)

Welch Two Sample t-test

data: x and y

t = 4.7191, df = 12.956, p-value = 0.0004048

검정통계량, 자유도, 유의확률

< 0.05

∴ 평균 다름

alternative hypothesis: true difference in means is not equal to 0

$H_1: \mu_1 \neq \mu_2$

$\mu_1 - \mu_2$   
95 percent confidence interval:

$0 \notin$  3.751376 10.090182

신뢰구간

sample estimates:

mean of x mean of y

26.66364 19.74286

표본평균

## $(\mu_1 - \mu_2)$ 에 대한 추론

- $(\mu_1 - \mu_2)$  의 95% 신뢰구간 = (3.75, 10.09)

$$26.66 - 19.74 - t_{0.025}(12.956) \sqrt{\frac{(4.51)^2}{11} + \frac{(1.45)^2}{7}} = 3.75$$

$$26.66 - 19.74 + t_{0.025}(12.956) \sqrt{\frac{(4.51)^2}{11} + \frac{(1.45)^2}{7}} = 10.09$$

- 가설  $H_0: \mu_1 = \mu_2$  vs.  $H_1: \mu_1 \neq \mu_2$

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{S_1^2/n_1 + S_2^2/n_2}} = \frac{(26.66 - 19.74) - 0}{\sqrt{(4.51)^2/11 + (1.45)^2/7}} = 4.7191,$$

$$\text{df} = 12.956$$

$$|T| \geq t_{0.025}(12.956) = qt(0.975, 12.956) = 2.16$$

$$p\text{-값} = P(|T| \geq |4.7191|)$$

$$= 2 * pt(-4.7191, 12.956) = 0.0004048 < 0.05$$

$H_0$  기각

$$\therefore \mu_1 \neq \mu_2$$




## 8.2 등분산 $T$ -검정

- $X_1, X_2, \dots, X_{n_1} \sim \text{iid } N(\mu_1, \sigma_1^2)$
- $Y_1, Y_2, \dots, Y_{n_2} \sim \text{iid } N(\mu_2, \sigma_2^2)$
- 독립표본
- $\sigma_1^2 = \sigma_2^2 = \sigma^2$  가정
- 가설  $H_0: \mu_1 = \mu_2$  vs.  $H_1: \mu_1 \neq \mu_2$
- 공통분산 (pooled var)

$$s_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{(n_1-1) + (n_2-1)}, \quad se(\bar{X} - \bar{Y}) = s_p \sqrt{1/n_1 + 1/n_2}$$

- 검정통계량  $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{s_p \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$
- $\mu_1 - \mu_2$ 의 100(1- $\alpha$ )% 신뢰구간  

$$\left( \bar{X} - \bar{Y} - t_{\alpha/2}(n_1 + n_2 - 2) s_p \sqrt{1/n_1 + 1/n_2}, \right. \\ \left. \bar{X} - \bar{Y} + t_{\alpha/2}(n_1 + n_2 - 2) s_p \sqrt{1/n_1 + 1/n_2} \right)$$
- 기각역  $R: |T| \geq t_{\alpha/2}(n_1 + n_2 - 2)$
- 유의확률  $p\text{-값} = P(|T| \geq |t_0|)$



### NOTE

$$S_1^2 = \frac{1}{n_1-1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2, \quad S_2^2 = \frac{1}{n_2-1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2$$

$$s_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{(n_1-1) + (n_2-1)}$$

$$E[\bar{X} - \bar{Y}] = \mu_1 - \mu_2$$

$$Var(\bar{X} - \bar{Y}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} = \sigma^2 \left( \frac{1}{n_1} + \frac{1}{n_2} \right)$$

$$Var(\widehat{\bar{X} - \bar{Y}}) = s_p^2 \left( \frac{1}{n_1} + \frac{1}{n_2} \right)$$

$$se(\bar{X} - \bar{Y}) = s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

## 예제 8.2 mtcars자료 표8.1에서 4기통 차와 6기통 차의 평균연비 비교

```
> x<-c(22.8, 24.4, 22.8, 32.4, 30.4, 33.9, 21.5, 27.3, 26.0, 30.4, 21.4)
```

```
> y<-c(21.0, 21.0, 21.4, 18.1, 19.2, 17.8, 19.7)
```

```
> mean(x)
```

```
> mean(y)
```

```
> sd(x)
```

```
> sd(y)
```

```
> mydata<-c(x,y)
```


```
> m<-length(x)
```

```
> n<-length(y)
```

```
> mygroup<-c(rep("4",m),rep("6",n))
```

```
> boxplot(mydata~mygroup, ylab="mpg")
```

실린더 수↵	평균↵	표준편차↵
4↵	26.66↵	4.51↵
6↵	19.74↵	1.45↵



$H_0: \mu_1 = \mu_2$  vs.  $H_1: \mu_1 \neq \mu_2$

> # 예제 8.3 ↵

> x <- mtcars[mtcars\$cyl=="4", "mpg"] ↵

자료 가져오기 ↵

> y <- mtcars[mtcars\$cyl=="6", "mpg"] ↵

> t.test(x,y, var.equal=TRUE) ↵

등분산 검정 표시하기 ↵

Two Sample t-test ↵

data: x and y ↵

t = 3.8952, df = 16, p-value = 0.001287 ↵

검정통계량, 자유도, 유의확률 ↵

< 0.05  
∴ 평균 다름

alternative hypothesis: true difference in means is not equal to 0 ↵

$H_1: \mu_1 \neq \mu_2$  ↵

95 percent confidence interval: ↵

3.154286 10.687272 ↵

신뢰구간 ↵

sample estimates: ↵

mean of x mean of y ↵

표본평균 ↵

26.66364 19.74286 ↵

$df = n_1 + n_2 - 2 = 16$

$\mu_1 - \mu_2$

## $(\mu_1 - \mu_2)$ 에 대한 추론

$$df = (11-1) + (7-1) = 16$$

$$s_p^2 = \frac{(11-1)(4.51)^2 + (7-1)(1.45)^2}{(11-1) + (7-1)} = 13.501$$

$(\mu_1 - \mu_2)$  의 95% 신뢰구간

$$26.66 - 19.74 - t_{0.025}(16) \sqrt{13.501 \sqrt{\frac{1}{11} + \frac{1}{7}}} = 3.15$$

$$26.66 - 19.74 + t_{0.025}(16) \sqrt{13.501 \sqrt{\frac{1}{11} + \frac{1}{7}}} = 10.69$$

$$CI = (3.15, 10.69)$$

$$H_0: \mu_1 = \mu_2 \text{ vs. } H_1: \mu_1 \neq \mu_2$$

$$T = T = \frac{(26.66 - 19.74) - 0}{\sqrt{13.501} \sqrt{1/11 + 1/7}} = 3.8952, \text{ df} = 16$$

$$|T| \geq t_{0.025}(16) = qt(0.975, 16) = 2.12$$

$$p\text{-값} = P(|T| \geq |3.8952|) = 0.001287$$

## 8.3 등분산성 검정을 위한 $F$ –통계량

- 독립표본

$$X_1, X_2, \dots, X_{n_1} \sim \text{iid } N(\mu_1, \sigma_1^2)$$

$$Y_1, Y_2, \dots, Y_{n_2} \sim \text{iid } N(\mu_2, \sigma_2^2)$$



- $H_0: \sigma_1^2 = \sigma_2^2$      $H_1: \sigma_1^2 \neq \sigma_2^2$     또는  $H_0: \frac{\sigma_1^2}{\sigma_2^2} = 1$      $H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq 1$

$$V_1 = \frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1 - 1), V_2 = \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2 - 1)$$

$$F = \frac{V_1/r_1}{V_2/r_2} = \frac{\frac{(n_1-1)S_1^2}{\sigma_1^2}/(n_1-1)}{\frac{(n_2-1)S_2^2}{\sigma_2^2}/(n_2-1)} = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

$$\text{검정통계량 } F = \frac{S_1^2}{S_2^2}$$

- $p$  – 값 =  $2P(F \geq f_0)$  또는  $2P(F \leq f_0)$



R 예제  $H_0: \sigma_1^2 = \sigma_2^2$      $H_1: \sigma_1^2 \neq \sigma_2^2$     또는  $H_0: \frac{\sigma_1^2}{\sigma_2^2} = 1$      $H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq 1$

```
> # 예제 8.4
```

```
> x <- c(22.8, 24.4, 22.8, 32.4, 30.4, 33.9, 21.5, 27.3, 26.0, 30.4, 21.4)     $n_1 = 11$ 
```

```
> y <- c(21.0, 21.0, 21.4, 18.1, 19.2, 17.8, 19.7)     $n_2 = 7$ 
```

```
> var.test(x,y)
```

F test to compare two variances

data: x and y

```
F = 9.6261, num df = 10, denom df = 6, p-value = 0.01182
```

검정통계량, 자유도  $n_1, n_2$ , 유의확률

<  $\alpha=0.05$  이므로,  $H_0$  기각함

alternative hypothesis: true ratio of variances is not equal to 1

$H_1: \sigma_1^2 \neq \sigma_2^2$

95 percent confidence interval:

```
1.762592 39.198688
```

신뢰구간

sample estimates:

ratio of variances

$\sigma_1^2 / \sigma_2^2$

$s_1^2 / s_2^2$

```
9.626086
```

$\sigma_1^2 / \sigma_2^2$

1  $\notin$

# 혼자 풀기

1. R의 mtcars에서 트랜스미션 자동(automatic) 19대와 수동(manual) 13대 차량의 mpg (연비)를 하여 SAS PROC TTEST을 실행한 결과, <표1>과 <표2>를 얻었다. 틀린 설명은 어느 것인가?

←

<표1> 등분산 검정 ←  $H_0: \sigma_1^2 = \sigma_2^2$   $H_1: \sigma_1^2 \neq \sigma_2^2$

Method	Num DF	Den DF	F Value	Pr > F
F	12	18	2.59	p= 0.0669

←  $\alpha = 0.05$  ∴ 등분산

←

<표2> ttest ←  $H_0: \mu_1 = \mu_2$   $H_1: \mu_1 \neq \mu_2$

Method	Variances	DF	t Value	Pr >  t
Pooled	Equal	30	-4.11	p= 0.0003
Satterthwaite	Unequal	18.332	-3.77	p= 0.0014

←  $\alpha = 0.05$  ∴ 평균 다름

- ① 독립인 이표본에서 평균을 비교하는 문제이고 검정통계량은 t이다. ←
- ② 유의수준 0.05에서 자동과 수동의 분산이 같다고 보기 어렵다. ←
- ③ 검정통계량은 t=-4.11이다. ←
- ④ 유의수준 0.05에서 두 집단의 평균이 다르다고 말할 수 있다. ←
- ⑤ 답 없음 ←

## 혼자 풀기 (시험)

14. R의 InsectSprays에서 spray B와 spray F를 뿌렸을 때 죽은 벌레 수가 다음과 같이 주어졌다. 정규분포를 가정할 때, spray B와 F를 뿌릴 때, 죽은 벌레 수가 같다고 말할 수 있을지 검정하자.

옳은 것을 모두 고르라. `var.test(x,y)` ; `t.test(x,y)`;  
`t.test(x,y,var.equal=T)`를 사용하자.

- a. 등분산 검정의 유의확률은  $p = 0.2294$ 이다.
- b. 두 평균의 동일성 검정에 대한 검정통계량  $t = -0.61259$ 의 자유도는 19.498이고, 유의확률은  $p = 0.5472$ 이다.
- c. 두 평균의 동일성 검정에 대한 검정통계량  $t = -0.61259$ 의 자유도는 22이고, 유의확률은  $p = 0.5464$ 이다.
- d. 유의수준 0.05에서 spray B와 F를 뿌릴 때, 죽은 벌레 수의 차이가 유의하게 다르다.

① a b    ② a c    ③ a b d    ④ a c d    ⑤ 위 보기 중

답 없음

B	11, 17, 21, 11, 16, 14, 17, 17, 19, 21, 7, 13
F	11, 9, 15, 22, 15, 16, 13, 10, 26, 26, 24, 13

```
x <- subset(InsectSprays, spray=="B", c(count) )
```

```
y <- subset(InsectSprays, spray=="F", c(count) )
```

```
x<-InsectSprays[InsectSprays$spray=="B", "count"]
```

```
y<-InsectSprays[InsectSprays$spray=="F", "count"]
```

```
x <- c(11, 17, 21, 11, 16, 14, 17, 17, 19, 21, 7, 13)
```

```
y <- c(11, 9, 15, 22, 15, 16, 13, 10, 26, 26, 24, 13)
```



## 실전 보고서 (과제)

R의 InsectSprays에서 B,F를 뿌릴 때, 죽는 벌레 수가 동일한지 검정하기 위하여, 유의수준 0.05에서 **이표본 T-검정**을 실시해보자. 그림1은 자료의 상자도표이다.

커저를 상자도표 그림에 놓고, 복사 붙이기

자르기로 크기 조절, 가운데 정렬

그림1. 살충제 B,F의 상자도표

두 스프레이를 뿌릴 때 죽은 평균 벌레수가 동일한지 알아보기 위하여, 다음과 같이 **가설**을 세우자.

$$H_0: \mu_B = \mu_F \quad H_1: \mu_B \neq \mu_F$$

삽입 => 수식 => 선택해서 입력

표본크기는 각각  $n_1 = ?$   $n_2 = ?$ 이고, **표본평균**은  $\bar{x} = ?$ ,  $\bar{y} = ?$ 이고, **표본표준편차**는  $s_X = ?$ ,  $s_Y = ?$ 이다. 등분산 검정에 대한 유의확률  $p = ?$ 가 유의수준  $\alpha = 0.05$ 보다 (크므로, 작으므로), (등분산이다, 이분산이다.)

(등분산 T-검정, 이분산 T-검정)을 이용하여 계산한 평균차이  $(\mu_B - \mu_F)$ 에 대한 **95% 신뢰구간**은  $(?, ??)$ 이고, **검정통계량**은  $T = ?$ 이며, **유의확률**은  $p = ?$ 이다. 따라서 유의수준 0.05 에서 귀무가설을 (기각한다, 기각하지 않는다. )즉, 유의수준 0.05에서 살충제 B와 F의 효과는 (같다, 다르다.)

## 부록

코드와 결과 붙이기

삽입 => 표 => 한 칸 선택

**(시험) 문제** 두 표본이  $X_1, X_2, \dots, X_{n_1} \sim \text{iid } N(\mu_1, \sigma_1^2), Y_1, Y_2, \dots, Y_{n_2} \sim \text{iid } N(\mu_2, \sigma_2^2)$  일 때,

$$\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i, S_1^2 = \frac{1}{n_1-1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2, S_2^2 = \frac{1}{n_2-1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2, s_p^2 =$$

$\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{(n_1-1) + (n_2-1)}$  에 대한 옳은 설명은 무엇인가?

①  $\frac{\bar{X} - \mu_1}{\sigma_1 / \sqrt{n_1}} \sim N(0, 1)$

②  $\frac{(n-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2 - 1)$

③  $\sigma_1^2 = \sigma_2^2 = \sigma^2$  일 때,  $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{s_p \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$

④  $\sigma_1^2 \neq \sigma_2^2$  일 때,  $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{S_1^2/n_1 + S_2^2/n_2}} \sim t(df), \quad df = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$

⑤  $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$

## 8.5 쌍체 비교법 (paired t-test) (생략)

- 두 약 A와 B의 생물학적 동등성을 검정하는 문제를 생각해보자.
- 체중이나 체질에 따라서 사람마다 두 약의 약효가 다르게 나타날 수 있기 때문에, 한 사람에게 두 약을 모두 투여한 후, 그 차이가 0인지를 검정한다.
- 이때, 앞서 투약되는 약의 잔여효과(carryover effect)가 나중에 투약되는 약의 효과에 영향을 미치지 않도록, 각 사람에게 투약되는 두 약의 순서를 랜덤하게 정해야 한다.



$$d_i = A_i - B_i, i=1, \dots, n$$

$$H_0: \mu_d = 0 \text{ vs. } H_1: \mu_d \neq 0$$

$$T = \frac{\bar{d}}{s_d/\sqrt{n}}$$

$$\bar{d} \pm t_{\alpha/2} (n-1) \frac{s_d}{\sqrt{n}}$$

$$R: |T| \geq t_{\alpha/2} (n-1)$$

$$p\text{-값} = P(|T| \geq |t_0|)$$

## 예제 8.6 두 간호사의 심장 신호를 측정 비교 (생략)

Id:↵	1	2	3	4	5	6	7	8	9	10	11	12↵
A↵	4.8,	5.6,	6.0,	<u>6.4,</u>	6.5,	6.6,	6.8,	7.0,	7.0,	7.2,	7.4,	7.6↵
B↵	5.8,	6.1,	7.7,	<u>7.8,</u>	7.6,	8.1,	8.0,	8.1,	6.6,	8.1,	9.5,	9.6↵

```
> # 예제 8.6 ↵
```

```
> A<-c(4.8,5.6,6.0,6.4,6.5,6.6,6.8,7.0,7.0,7.2,7.4,7.6)↵
```

```
> B<-c(5.8,6.1,7.7,7.8,7.6,8.1,8.0,8.1,6.6,8.1,9.5,9.6)↵
```

```
> t.test(A,B, paired=T)↵
```

Paired t-test↵

쌍체비교↵

data: A and B↵

t = -6.0237, df = 11, p-value = 8.628e-05↵

검정통계량, 자유도, 유의확률↵

alternative hypothesis: true difference in means is not equal to 0↵

95 percent confidence interval:↵

-1.6043289 -0.7456711↵

신뢰구간↵

sample estimates:↵

mean of the differences ↵

-1.175↵

평균차이  $\bar{d}$ ↵